

Detecção Eficiente de Incêndios Florestais em Dispositivos de Borda Utilizando Aprendizado Profundo e Quantização Pós-treinamento

Pedro Marcio Raposo Pereira

Inatel
Santa Rita do Sapucaí, Brasil
pedro.marcio@inatel.br

TP557 - Tópicos avançados em IoT e Machine Learning, 29 de Novembro de 2023

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais
- 4 Metodologia
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências
- 8 Perguntas

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais
- 4 Metodologia
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências
- 8 Perguntas

Contextualização: Incêndios florestais como uma ameaça crítica.

- Mais de 370 milhões de hectares de terras sucumbem a incêndios florestais, resultando na emissão de aproximadamente 1,8 bilhão de toneladas de gases de efeito estufa na atmosfera.
- A poluição do ar induzida por incêndios florestais está associada a cerca de 340.000 mortes prematuras anualmente, predominantemente atribuídas a complicações respiratórias e cardiovasculares [1, 2].

Tradicionalmente, entre as ferramentas disponíveis para a detecção de incêndios florestais, destacam-se:

- Relatos públicos e patrulhas aéreas com observadores treinados desempenham papel crucial na detecção precoce de incêndios em áreas remotas.
- A detecção auxiliada por computador na gestão de incêndios utiliza dados meteorológicos em tempo real e monitoramento de raios para avaliar riscos e prever comportamentos do fogo [3].

A proposta deste trabalho busca superar desafios enfrentados pelos métodos tradicionais, oferecendo uma solução eficiente e economicamente viável para a detecção de incêndios florestais.

Ao contrário das técnicas auxiliadas por computador, frequentemente dispendiosas, a abordagem proposta utiliza aprendizado profundo adaptado para ambientes com recursos limitados, fazendo uso de hardware de baixo custo e algoritmos energeticamente eficientes.

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados**
- 3 Materiais
- 4 Metodologia
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências
- 8 Perguntas

- Um framework de aprendizado profundo para a detecção precoce de incêndios florestais, fazendo uso de imagens multiespectrais provenientes dos Satélites Ambientais Operacionais Geoestacionários (*Geostationary Operational Environmental Satellites*, GOES) foi proposto em [4].
 - Desempenho promissor, mas requer avaliação aprofundada em eficiência computacional e robustez.
- Em [5] é proposto utilizar-se *transformers* para a segmentação de incêndios florestais por Veículos Aéreos Não Tripulados (VANTs)
 - Alcança precisão de 85,12%, mas não discute otimização para dispositivos de baixo desempenho.
- Um protótipo de sistema funcional capaz de detectar a fumaça de incêndios florestais em até 15 minutos após a ignição, com uma média de menos de um falso positivo por dia por câmera, é proposto em [6].
 - Baseia-se no modelo Inception V3, mas demanda infraestrutura de rede centralizada e custos elevados.

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais**
- 4 Metodologia
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências
- 8 Perguntas

Os materiais utilizados para o projeto foram

- Arduino Nano 33 BLE Sense
- Sensor óptico OV7675.
- Para otimizar a implementação, adotou-se a plataforma *Edge Impulse* (EI).



Figura 1: Placa Nano 33 BLE Sense.



Figura 2: Sensor Óptico OV7675.

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais
- 4 Metodologia**
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências
- 8 Perguntas

- Banco de Dados:
 - Utilização do banco de dados "Forest Fire Images" disponível no Kaggle.
- Pré-processamento:
 - Exclusão de imagens repetidas no banco de dados.
 - Subdivisão dos conjuntos de treinamento e teste na proporção 80%-20%.
 - Detalhes da divisão apresentados na Tabela 1.

Tabela 1: Divisão do Banco de Dados em conjunto de treinamento e validação.

	fogo	normal	total
treinamento	1667	1657	3324
teste	424	418	842
			4166

Processamento de Dados

- Subamostragem:
 - Padronização para a resolução de 96x96 pixels.
- Normalização:
 - Normalização das imagens multiplicando-as por um fator de escala de $1/255$.
 - Garantia de que os valores dos pixels estejam no intervalo $(0, 1)$ para melhor aprendizagem do modelo.



Figura 3: Exemplo de imagens após o processamento.

Desenvolvida para dispositivos móveis, o MobileNet é uma Redes Neurais Convolucionais (*Convolutional Neural Networks*, CNN) eficiente, mantendo baixa complexidade e requisitos de memória. Destaca-se por

- Introduz convoluções separáveis em profundidade, dividindo o processo em convolução em profundidade e pontual. Reduz custo computacional e parâmetros.
- Utiliza normalização em lote para acelerar treinamento e melhorar generalização, enquanto a função de ativação ReLU introduz não-linearidades.
- Aplica *pooling* para reduzir resolução espacial, preservando informações cruciais e descartando detalhes menos relevantes.

Devido a restrições de hardware, o projeto utiliza apenas 25% da profundidade do MobileNet, mantendo eficácia na extração de características.

Arquitetura do Classificador

A arquitetura do classificador é formada pelas seguintes camadas

- Entrada: Recebe imagens em formato (96, 96, 3), indicando resolução de 96x96 pixels e canais RGB.
- MobileNet 25%: Processa a entrada, resultando em saída (3, 3, 1280), representando características extraídas.
- Reformulação (*reshape*): Preserva a dimensão mais externa e agrupando as dimensões internas, resultando em um formato de (9, 1280).
- Camada Densa: Atua apenas na dimensão mais externa, resultando em uma saída de (9, 16).
- Achatamento (*Flatten*): transforma a saída para uma representação unidimensional de (144).
- Camada Densa: Agrega informações e permite a diferenciação entre as duas classes desejadas.

Tabela 2: Arquitetura do Modelo.

Camada	Formato de Saída	# Parâmetros
Entrada	(96, 96, 3)	0
MobileNet 25%	(3, 3, 1280)	410208
reshape	(9, 1280)	0
densa	(9, 16)	20496
dropout	(9, 16)	0
flatten	(144)	0
densa	(2)	290
Total:		430994

Treinamento e Quantização

Inicialmente, utiliza-se o MobileNet pré-treinado no ImageNet como modelo base. Aplica-se uma técnica de aumento de dados, como espelhamento e ajuste de brilho, para enriquecer o conjunto de treinamento. O treinamento é dividido em duas partes:

- Treinamento Inicial: Treina o modelo com a camada MobileNet congelada ao longo de 20 épocas, utilizando Adam como otimizador, passo de aprendizagem de 0,0005 e entropia cruzada categórica como função de perda.
- Ajuste Fino: Realiza o ajuste fino descongelando 65% das camadas superiores do MobileNet. Continua o treinamento por mais 10 épocas com um passo de aprendizagem de 0,000045.

Após o treinamento, realiza-se uma quantização completa. Converte pesos e funções de ativação para inteiros de 8 bits (int 8), reduzindo significativamente o tamanho e a complexidade do modelo.

Quantização pós-treinamento

Utiliza a Biblioteca Arduino do EI para implementar o modelo em placas de desenvolvimento Arduino baseadas em ARM. Funcionamento da Aplicação:

- Inicializa a câmera OV7675, configura os pinos dos LEDs para indicar detecção de incêndio e define um limiar de probabilidade.
- Em um loop contínuo, capta imagens da câmera, redimensiona para as dimensões do modelo, normaliza e executa o modelo de detecção de incêndios.
- Com base na probabilidade da classe Incêndio, acende LEDs indicativos (vermelho ou azul). O loop continua até ser interrompido pelo usuário.




Figura 4: Diagrama do sistema de detecção de incêndios.

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais
- 4 Metodologia
- 5 Resultados**
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências
- 8 Perguntas

Curvas de treinamento

Os valores de perda e acurácia estão próximos para o conjunto de treinamento e validação, portanto, não há sobreajuste.




Figura 5: Perda do modelo durante as épocas de treinamento.




Figura 6: Acurácia do modelo durante as épocas de treinamento.

Desempenho do Modelo Quantizado

A Tabela 3 apresenta uma comparação entre os resultados de dois modelos distintos para a detecção de incêndios: o Modelo Float32 e o Modelo Quantizado sobre o conjunto de testes.

Tabela 3: Análise das métricas de Classificação para os modelos em ponto flutuante e inteiro.

Modelo Float32					
	Classe	Precisão	Recall	F1-score	Suporte
	Fogo	0.953	0.958	0.955	424
	Normal	0.957	0.952	0.954	418
Acurácia				0.955	842
Média Macro		0.955	0.955	0.955	842
Média Ponderada		0.955	0.955	0.955	842
Modelo Quantizado					
	Classe	Precisão	Recall	F1-score	Suporte
	Fogo	0.976	0.950	0.963	424
	Normal	0.951	0.976	0.963	418
Acurácia				0.963	842
Média Macro		0.963	0.963	0.963	842
Média Ponderada		0.964	0.963	0.963	842

Desempenho do Modelo Quantizado

Prosseguindo a análise com o modelo quantizado, a Figura 7 detalha o desempenho do modelo para o conjunto de testes por meio da matriz de confusão.

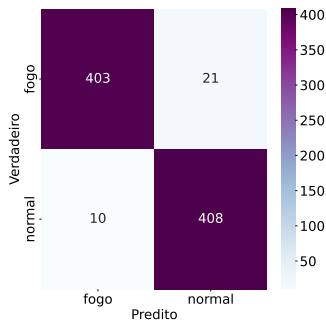


Figura 7: Matriz de Confusão para o conjunto de Testes.

Exemplo de Classificação

A Figura 8 mostra os resultados da execução do classificador quantizado em 10 imagens aleatórias do conjunto de testes. O classificador identificou corretamente 9 figuras, das quais 8 foram com altos índices de confiança.



Figura 8: Exemplo de classificações para o modelo quantizado




Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais
- 4 Metodologia
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras**
- 7 Referências
- 8 Perguntas

Resultados e Desempenho do Modelo

- O modelo de detecção de incêndios florestais baseado em MobileNet, se mostrou robusto após a quantização pós-treinamento.
- O treinamento e avaliação no conjunto de dados diversificado mostraram desempenho robusto, alcançando alta precisão, recall e F1-score para ambas as classes (Fogo e Normal).

Implementação Prática

- Nos testes práticos, o sistema demonstrou acionamento correto do LED vermelho em situações de detecção de incêndio.

Limitações Identificadas

- Identificamos limitações, como restrições no ângulo de visão da câmera e desafios nos testes em ambientes reais.

Expansão do Ângulo de Visão

- Explorar tecnologias de câmeras com ângulos mais amplos.

Integração de Sensores Adicionais

- Incorporar sensores de temperatura, umidade e gases.

Aplicações Além de Incêndios Florestais

- Adaptar o modelo para monitoramento urbano e industrial.

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais
- 4 Metodologia
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências**
- 8 Perguntas

- [1] U. Nations, "As Wildfires Increase, Integrated Strategies for Forests, Climate, and Sustainability Are Ever More Urgent," <https://www.un.org/en/un-chronicle/wildfires-increase-integrated-strategies-forests-climate-and-sustainability-are-ever-0>, 2023, [Online; acessado em 20-Novembro-2023].
- [2] U. N. E. Programme, "Number of Wildfires to Rise by 50% by 2100 and Governments Are Not Prepared," <https://www.unep.org/news-and-stories/press-release/number-wildfires-rise-50-2100-and-governments-are-not-prepared>, 2022, [Online; acessado em 20-Novembro-2023].
- [3] G. of the Northwest Territories, "Detecting wildfire," <https://www.gov.nt.ca/ecc/en/services/wildfire-operations/detecting-wildfire>, [Online; acessado em 20-Novembro-2023].
- [4] N. T. Toan, P. Thanh Cong, N. Q. Viet Hung, and J. Jo, "A deep learning approach for early wildfire detection from hyperspectral satellite images," in *2019 7th International Conference on Robot Intelligence Technology and Applications (RiTA)*, 2019, pp. 38–45.
- [5] R. Ghali, M. A. Akhloufi, and W. S. Mseddi, "Deep learning and transformer approaches for uav-based wildfire detection and segmentation," *Sensors*, vol. 22, no. 5, 2022. [Online]. Available: <https://www.mdpi.com/1424-8220/22/5/1977>
- [6] K. Govil, M. L. Welch, J. T. Ball, and C. R. Pennypacker, "Preliminary results from a wildfire detection system using deep learning on remote camera images," *Remote Sensing*, vol. 12, no. 1, 2020. [Online]. Available: <https://www.mdpi.com/2072-4292/12/1/166>

Tabela de Conteúdos

- 1 Introdução
- 2 Trabalhos Relacionados
- 3 Materiais
- 4 Metodologia
- 5 Resultados
- 6 Conclusão e Propostas de Pesquisas Futuras
- 7 Referências
- 8 Perguntas**

Dúvidas e Perguntas

Obrigado!